

Da Planilha Caótica ao Modelo Relacional em 3FN

Inteligência de preços para a Rede Maré Combustíveis

Aluno: Guilherme Bazani Demuner · **Curso:** Ciência de Dados para Negócios · **Disciplina:** Modelagem Informacional
Avaliação: Trabalho Prático 1 (T1) — Trilha C: Modelagem Relacional, Normalização até 3FN e SQL · **FUCAPE Business School**, 2026

1. Contexto e Dor de Negócio

A **Rede Maré Combustíveis** é um grupo capixaba de bandeira branca com cinco postos na Grande Vitória (Vitória, Vila Velha, Serra e dois em Cariacica). Por não ter contrato com distribuidora, compete principalmente por preço, e sua decisão semanal de precificação depende de acompanhar os concorrentes. Hoje, o analista de pricing consolida os dados da pesquisa semanal da ANP numa **planilha única**, acrescentando colunas próprias: lista de concorrentes diretos, serviços, gerente e telefones.

Essa tabela universal mistura cinco assuntos numa só linha (coleta, posto, localização, produto e dados internos) e produz as três anomalias clássicas. **Inserção:** um posto novo só pode ser cadastrado quando houver preço coletado. **Atualização:** a troca de um gerente exigiu editar 11 linhas, e 3 ficaram desatualizadas. **Exclusão:** apagar o histórico de um concorrente apaga também seu cadastro e o vínculo de concorrência. O efeito no negócio é direto: sem enxergar a concorrência com confiança, a rede precifica às cegas, ora abaixo do mercado (perdendo margem), ora acima (arriscando volume).

Para medir o problema, foram definidos os KPIs abaixo, calculados sobre a planilha no estado atual (baseline):

KPI de qualidade e operação	Planilha (antes)	Modelo 3FN (depois)
Células cadastrais repetidas	16.224	0
Postos com grafias divergentes de razão social	79 de 158	Impossível (1 linha por CNPJ)
Linhas editadas para trocar um gerente	11 (3 com erro)	1
Linhas com listas numa única célula (violação da 1FN)	2.149 (98%)	0
Linhas duplicadas	10	Bloqueadas por PK/UNIQUE
Visibilidade de preço vs. concorrentes diretos	Manual	Automática (VIEW semanal)

2. Metodologia

Por que a Trilha C. A dor da Rede Maré é estrutural: os erros nascem do próprio desenho da planilha, não do volume de dados nem da velocidade de consulta. Por isso, a solução adequada é a modelagem relacional com normalização, e não otimizações de I/O ou armazenamento colunar. A normalização elimina as anomalias na origem, e as constraints impedem que elas voltem.

Dados. A base é a Série Histórica de Preços de Combustíveis da ANP (1º semestre de 2026), recortada para o Espírito Santo: 7.717 preços de 158 postos em 10 municípios. São **reais** os postos concorrentes, endereços, bandeiras, datas e preços. São **simulados**, com semente fixa e de forma documentada, as colunas internas da empresa e as sujeiras de digitação. Os cinco postos da Rede Maré são postos reais de bandeira branca, **anonimizados** (CNPJ e razão social fictícios) para não atribuir a narrativa a empresas reais.

Pipeline reproduzível. Recorte da ANP → geração da planilha caótica → limpeza de formato → 1FN → 2FN → 3FN (Python/pandas, PEP8) → DDL e carga no PostgreSQL → VIEWS analíticas → testes automatizados → cálculo do ROI. Cada etapa grava suas tabelas intermediárias, permitindo auditar a normalização linha a linha.

3. Resultados e Discussão

3.1 Normalização

As dependências funcionais foram levantadas e confirmadas nos dados (por exemplo, a combinação posto + data + produto nunca se repete, e cada produto tem uma única unidade de medida). A tabela resume a decomposição:

Etapa	Violação tratada	Resultado
Limpeza	Grafias divergentes, CNPJ com máscara, datas em dois formatos, 10 duplicatas	2.176 linhas padronizadas
1FN	Listas paralelas (produto, preço, unidade), endereço composto, serviços, telefones e concorrentes multivalorados	Chave (cnpj, data, produto): 7.717 linhas + 3 relações para os multivalorados
2FN	Dependências parciais: produto → unidade; cnpj → cadastro; (cnpj, data) → bandeira	Padrão cabeçalho-itens: COLETA / ITEM_COLETA
3FN	Transitivas: município → UF → região; CNPJ raiz → grupo; gerente → telefones; data → semana (derivada)	14 tabelas; semana passa a ser calculada na VIEW

Três achados merecem destaque. Primeiro, **achatar** todos os multivalorados juntos na 1FN geraria um produto cartesiano de 23.465 linhas com fatos falsos, o que justificou separar cada multivalorado em relação própria. Segundo, a 1FN isolada **piorou** a redundância (de 43,5 mil para 154 mil células), confirmando que só a 2FN e a 3FN resolvem as anomalias. Terceiro, os dados reais mostraram quatro postos que **trocam de bandeira** no semestre; por isso a bandeira foi modelada como atributo da coleta (a bandeira observada no dia), preservando o histórico sem inventar datas de vigência que a ANP não informa.

3.2 Diagrama Entidade-Relacionamento




Figura 1 — DER lógico em 3FN (versão Mermaid.js no repositório). Azul: núcleo transacional; dourado: dados internos da Rede Maré; cinza: dimensões de contexto. Notação pé-de-galinha.

3.3 Integridade referencial e testes

O DDL implementa PRIMARY KEY, FOREIGN KEY, UNIQUE e CHECK em todas as tabelas, com política explícita de exclusão: CASCADE nas entidades fracas (itens e telefones), RESTRICT no histórico de preços e SET NULL no gerente. Uma **FK composta** garante, sem triggers, que o lado “próprio” da concorrência seja um posto da rede, e um CHECK exige que a raiz do grupo econômico coincida com o CNPJ. O script de testes executa **19 cenários** dentro de uma transação revertida: as três anomalias deixaram de existir, 8 regras de domínio e 6 regras de chave e referência rejeitaram dados inválidos. **Resultado: 19 de 19 aprovados.**

Durante a carga, o CHECK de data rejeitou uma coleta em 02/11/2026. A investigação revelou um erro no próprio script de limpeza: a detecção automática de formato havia invertido dia e mês em 26 das 59 datas em formato ISO, das quais só uma caiu no futuro. As outras 25 teriam entrado erradas em silêncio. O episódio ilustra o papel das constraints como última linha de defesa e também seu limite: elas barram o impossível, não o plausível e errado.

3.4 Visões analíticas para a decisão

Quatro VIEWS com JOINS ANSI entregam a visão de negócio: **vw_coleta_completa** (visão desnormalizada para dashboards), **vw_posicionamento_concorrencia** (preço semanal de cada posto vs. média dos concorrentes diretos), **vw_painel_rede_mare** (consolidado do semestre) e **vw_evolucao_preco_bandeira**. Os resultados são reveladores: o posto **Horto** vendeu etanol abaixo dos concorrentes em 100% das semanas, em média R\$ 0,20/litro mais barato, e a gasolina aditivada ficou abaixo do mercado em praticamente todas as semanas em quatro dos cinco postos. No sentido oposto, o posto **Itaquari** esteve acima dos concorrentes na gasolina comum em 69% das semanas (+R\$ 0,11/litro), um risco de perda de volume. Em todo o ES, a bandeira branca foi, mês a mês, entre R\$ 0,00 e R\$ 0,10/litro mais barata que a média do mercado na gasolina, enquanto os postos Maré chegaram a praticar descontos de R\$ 0,15 a R\$ 0,31/litro frente aos seus concorrentes diretos.

4. Conclusão de Negócios e ROI

O ganho financeiro vem da decisão que o modelo passa a suportar: eliminar descontos desnecessários frente aos concorrentes diretos. Para cada posto e produto, a margem deixada na mesa é *volume × participação do produto × frequência de semanas abaixo × gap médio*. As premissas estão declaradas e parametrizadas no script **05_roi.sql**:

Premissa	Valor adotado	Fonte
Volume médio por posto	178 mil litros/mês	Fecombustíveis (audiência na Câmara dos Deputados, 2017)
Mix de vendas	Gasolina 50%, aditivada 10%, etanol 15%, diesel S10 20%, diesel 5%	Hipótese do autor (posto urbano)
Captura do gap	25% / 50% / 100%	Cenários: parte do desconto pode ser estratégica
Investimento	R\$ 9.600 (120 h × R\$ 80/h) + R\$ 200/mês de servidor	Hipótese do autor




Figura 2 — Margem deixada na mesa por posto e produto no teto teórico (captura de 100%), calculada a partir de **vw_painel_rede_mare**.

Cenário	Ganho mensal	Ganho anual	Payback do investimento
Conservador (25%)	R\$ 14,5 mil	R\$ 174 mil	≈ 20 dias
Base (50%)	R\$ 29,0 mil	R\$ 348 mil	≈ 10 dias
Teto (100%)	R\$ 58,0 mil	R\$ 697 mil	≈ 5 dias

Mesmo no cenário conservador, o investimento se paga em menos de um mês. Além do ganho financeiro, há um ganho **operacional** (cadastros atualizados em uma linha, sem retrabalho nem inconsistência) e um ganho **analítico** (preço vs. concorrência disponível toda semana, pronto para BI). **Limitações:** o volume e o mix são premissas, não dados da empresa; o modelo não estima a elasticidade da demanda, então subir preço pode reduzir volume; e os ganhos dependem de o time de pricing agir sobre as informações. O modelo relacional não gera receita sozinho: ele torna confiável e visível a informação que sustenta a decisão.

Recomendação. Adotar o modelo relacional como fonte única da verdade, conectar a **vw_posicionamento_concorrencia** a um dashboard semanal e começar pelos casos mais evidentes: rever o

etanol e a gasolina aditivada do Horto e a gasolina aditivada de Campo Grande (abaixo do mercado em 100% das semanas), e monitorar a gasolina do Itaquari (acima do mercado em 69% das semanas). Como próximos passos, o modelo comporta a base nacional da ANP sem alteração estrutural e pode evoluir com histórico de gerência e dados reais de volume.

Entregáveis

O pacote do trabalho contém: **dados/** — recorte da ANP, planilha caótica, métricas de baseline e os scripts Python de recorte, geração e normalização, com as tabelas de cada forma normal; **modelagem/** — `normalizacao.md` (dependências funcionais e decomposição passo a passo) e `der.md` (DER em Mermaid.js); **sql/** — `01_ddl`, `02_carga`, `03_views`, `04_testes` e `05_roj`; e **README.md** com o passo a passo para reproduzir tudo no Windows.

Referências

AGÊNCIA NACIONAL DO PETRÓLEO, GÁS NATURAL E BIOCOMBUSTÍVEIS (ANP). *Série Histórica de Preços de Combustíveis e de GLP* — Combustíveis automotivos, 1º semestre de 2026. Portal de Dados Abertos do gov.br.

FECOMBUSTÍVEIS. *Preços dos combustíveis no país*. Apresentação em audiência pública, Câmara dos Deputados, 2017 (volume médio mensal de vendas por posto).

PERIN, W. *Modelagem Informacional* — Aulas 01 a 06 (normalização, DER e laboratórios de modelagem relacional). FUCAPE Business School, 2026.